



הקדמה

במהלך שנת 2019 התבצעה תחרות בתחום הראייה
הממוחשבת מטעם משרד הבטחון :

MAFAT Challenge : <https://mafatchallenge.mod.gov.il/>

התחרות כללה סיווג תמונות רחפן לפי קטגוריות ומאפיינים
נתונים, תוך שימוש בלמידה עמוקה.

בפרויקט זה עסקנו בפתרון בעיית הסיווג לעיל לפי
הקריטריונים שסופקו בתחרות.

במהלך המצגת הבאה נציג את מטרת הפרויקט, הרקע
לפתרון, הפתרון עצמו וסיכום.



מטרת הפרויקט

סיווג אובייקטים שונים הנמצאים בנתוני תמונות אוויריות ממבט הרחפן. הסיווג כולל סיווג גם למחלקות עיקריות (רכב גדול או קטן), וסיווג עדין של תתי מחלקות ותכונות ייחודיות (למשל - מכונית עם גלגל רזרבי).

1. Small vehicle

- a. Subclasses - Sedan, Hatchback, Minivan, Van, Pickup truck, Jeep, Public vehicle.
- b. Features - Sunroof, Luggage carrier, Open cargo area, Enclosed cab, Wrecked, Spare wheel.
- c. Colors - Yellow, Red, Blue, Black, Silver/Grey, White, Other.

2. Large vehicle

- a. Subclasses - Truck, Light truck, Cement mixer, Dedicated agricultural vehicle, Crane truck, Prime mover, Tanker, Bus, Minibus.
- b. Features - Open cargo area, AC vents, Wrecked, Enclosed box, Enclosed cab, Ladder, Flatbed, Soft shell box, Harnessed to a cart.
- c. Colors - Yellow, Red, Blue, Black, Silver/Grey, White, Other.



מטרת הפרויקט - דוגמא





רקע

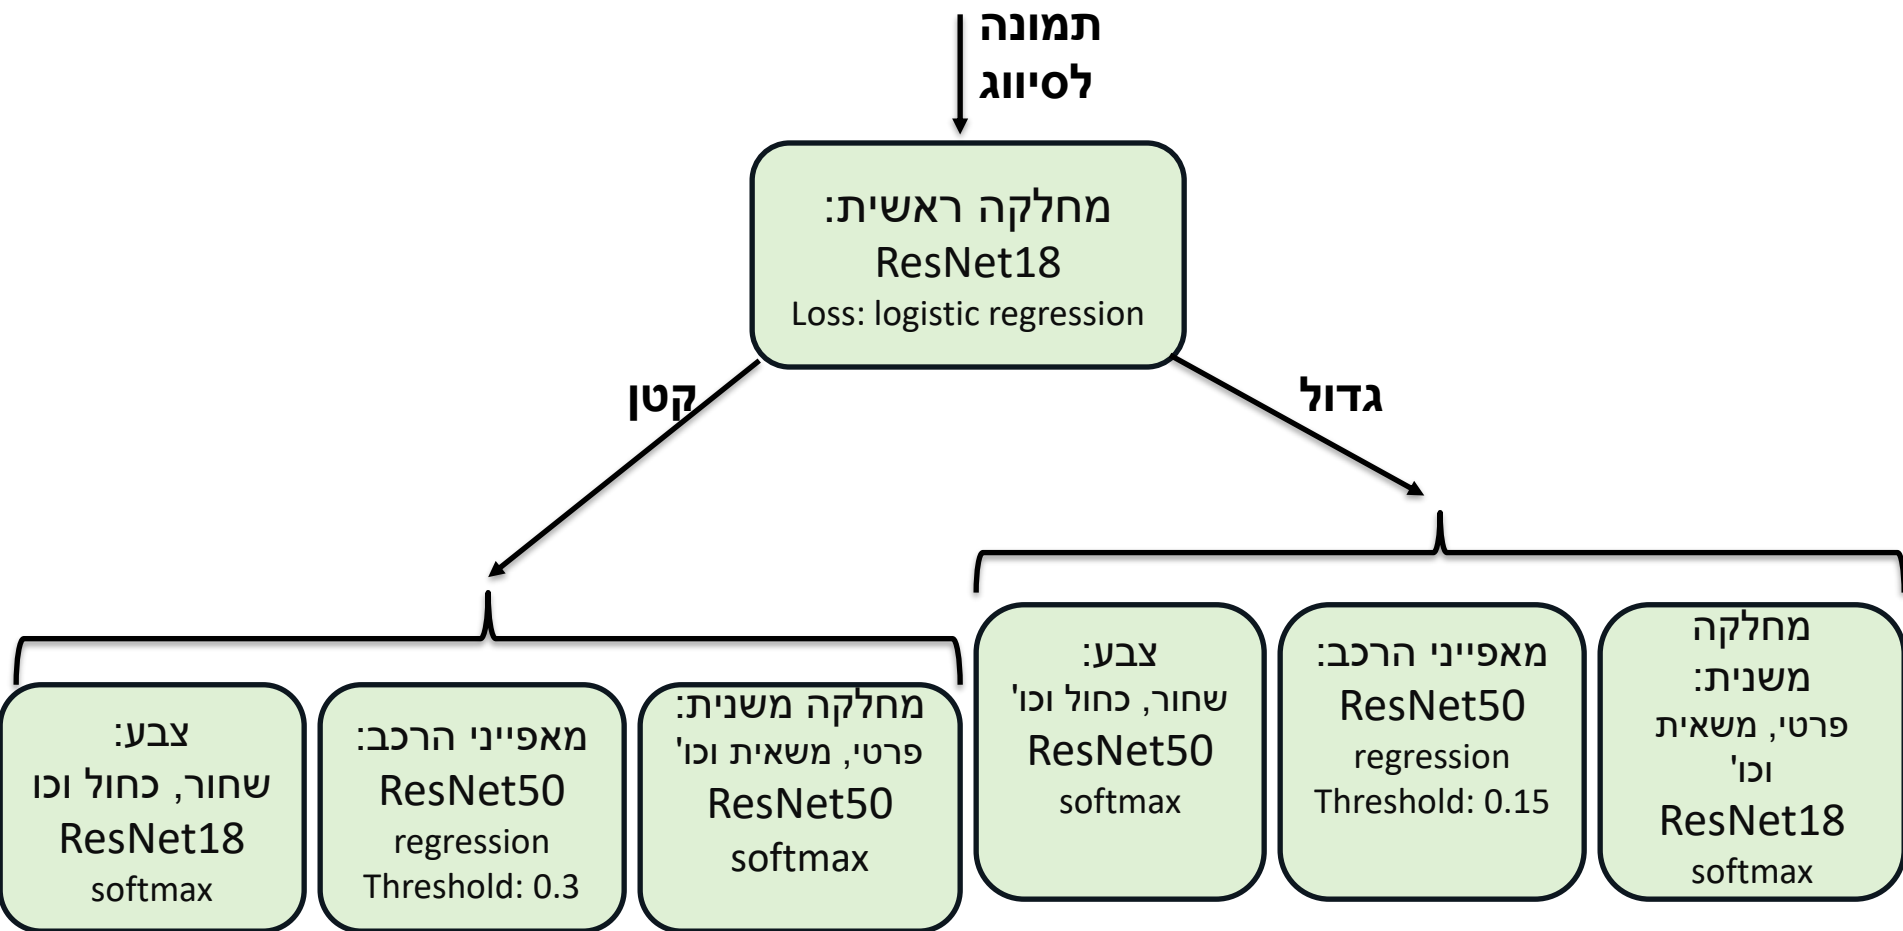
לאחר ניצחון רשת הקונבולוציה AlexNet^[1] בתחרות ImageNet בשנת 2012, התבססה טכנולוגיית הלמידה העמוקה (באמצעות CNN) כפתרון היעיל ביותר עבור בעיית סיווג תמונות.

כיום, אחת הרשתות הנפוצות לסיווג היא ResNet^[2]. בפרויקט זה השתמשנו בהרכבת רשתות קונבולוציה על מנת לסווג בצורה היררכית את המאפיינים השונים (עקב תלות במאפיינים).



הפתרון שנבחר

ארכיטקטורה





הפתרון שנבחר

פירוט (1)

ע"מ להבין את הפתרון, נציג ראשית את הבעיה המרכזית שאיתה התמודדנו:

Imbalanced Data – מידע לא מאוזן -

בעיה שכיחה בלמידת מכונה (בעיית הסיווג), כאשר יש יחס לא פרופורציונאלי של דגימות בכל מחלקה. מכיוון שבלמידה עמוקה אנו מנסים למזער פונקציית מחיר, מידע לא מאוזן בצורה קיצונית יכולה לגרור תוצאת חיזוי דטרמיניסטית (למשל, אם 95% מהדגימות הן ממחלקה '1', אם הרשת תחזה תמיד '1' היא תדייק ב-95% מהמקרים, מה שיגרור כנראה מחיר נמוך כנדרש)



הפתרון שנבחר

פירוט (2)

דוגמא לחוסר איזון בכלל המידע (אימון ובוחן):

מחלקה עיקרית			גודל	כמות	אחוז מכלל המידע
			רכב קטן	8651	96.40%
			רכב גדול	317	3.60%
צבע			גודל	כמות	אחוז מכלל המידע
			שחור	939	11%
			כחול	576	6.80%
			ירוק	55	<1%
			צהוב	57	<1%
			אדום	252	3%
			אפור/כסוף	3004	36%
			לבן	3157	37%
			אחר	407	5%

* כאשר עבור כל מאפיין מהמאפיינים העדינים, אחוז הדגימות החיוביות קטן מ-5% מכלל המידע.



הפתרון שנבחר

פירוט (3)

פתרון הבעיה:

- אוגמנטציה סלקטיבית (הוספת דגימות) ^[3]
- פונקצית מחיר ממושקלת
- סיווג היררכי תלוי ^[4]
 - נטרול גרירת חוסר האיזון
 - הגדרה שונה לבעיה עבור המחלקות השונות
 - מתאפשר בזכות דיוק גבוה בסיווג המחלקה העיקרית



אבני דרך

- תחילת הפרויקט ללא ידע בלמידה עמוקה – השלמת הפערים באופן עצמאי.
- ניסיון פתרון הבעיה העיקרית ללא ניתוח המידע – הבנה בדיעבד של בעית חוסר האיזון.
- **ניתוח וניקוי המידע**
- ניסיון לפתור את הבעיה העיקרית בעזרת שיטות ML קלאסיות – ניתוח מאפיינים (לא נבחר)
- **פונקצית מחיר ממושקלת, אוגמנטציות סלקטיביות**
- אימון שכבות FC בלבד (לא נבחר)
- אימון וחיזוי מקבילי – בלתי תלוי (לא נבחר)
- **אימון וחיזוי היררכי תלוי.**



תוצאות

אחוזים (1)

```
Accuracy of the general_class network on the 1795 test images: 98 %
Accuracy of the general_class network on the 60 'large class' test images: 100 %
-----
Accuracy of the color network on the 1795 test images: 97 %
-----
Accuracy of the sub_class network on the 1795 test images: 97 %
-----
Accuracy of the open_cargo_area network on the 1795 test images: 99 %
Accuracy of the open_cargo_area network on the 34 positive test images: 91 %
-----
Accuracy of the wrecked network on the 1795 test images: 99 %
Accuracy of the wrecked network on the 74 positive test images: 96 %
-----
Accuracy of the flatbed network on the 1795 test images: 98 %
Accuracy of the flatbed network on the 7 positive test images: 100 %
-----
Accuracy of the ladder network on the 1795 test images: 98 %
Accuracy of the ladder network on the 0 positive test images: NaN
-----
Accuracy of the enclosed_box network on the 1795 test images: 98 %
Accuracy of the enclosed_box network on the 17 positive test images: 88 %
-----
Accuracy of the soft_shell_box network on the 1795 test images: 98 %
Accuracy of the soft_shell_box network on the 3 positive test images: 67 % (2 of 3!)
```



תוצאות


אחוזים (2)

```
Accuracy of the  harnessed_to_a_cart  network on the  1795  test images: 98 %  
Accuracy of the  harnessed_to_a_cart  network on the   1  positive test images: 100 %  
-----  
Accuracy of the  sunroof  network on the  1795  test images: 98 %  
Accuracy of the  sunroof  network on the  163  positive test images: 93 %  
-----  
Accuracy of the  luggage_carrier  network on the  1795  test images: 98 %  
Accuracy of the  luggage_carrier  network on the   72  positive test images: 89 %  
-----  
Accuracy of the  enclosed_cab  network on the  1795  test images: 98 %  
Accuracy of the  enclosed_cab  network on the   22  positive test images: 77 %  
-----  
Accuracy of the  spare_wheel  network on the  1795  test images: 98 %  
Accuracy of the  spare_wheel  network on the   25  positive test images: 84 %  
-----
```



תוצאות

גרפים - כללי







תוצאות

גרפים - מאפיינים

שלילים בלבד:



חיוביים בלבד:





תוצאות סיווג צבע

Accuracy of the green network on the 11 test images: 100 %

11 11

Accuracy of the yellow network on the 12 test images: 83 %

10 12

Accuracy of the red network on the 56 test images: 100 %

56 56

Accuracy of the blue network on the 139 test images: 99 %

138 139

Accuracy of the black network on the 205 test images: 99 %

203 205

Accuracy of the white network on the 664 test images: 99 %


661 664

Accuracy of the silver/grey network on the 625 test images: 97 %

612 625

Accuracy of the other network on the 83 test images: 97 %

81 83





תוצאות

סיווג תת מחלקה

Accuracy of the bus network on the 7 test images: 100 %

Accuracy of the cement mixer network on the 3 test images: 100 %

Accuracy of the crane truck network on the 1 test images: 100 %

Accuracy of the dedicated agricultural vehicle network on the 1 test images: 100 %

Accuracy of the light truck network on the 9 test images: 100 %

Accuracy of the minibus network on the 4 test images: 100 %

Accuracy of the prime mover network on the 10 test images: 80 %

Accuracy of the tanker network on the 0 test images: NaN

Accuracy of the truck network on the 25 test images: 100 %

Accuracy of the hatchback network on the 505 test images: 98 %


Accuracy of the jeep network on the 160 test images: 96 %

Accuracy of the minivan network on the 101 test images: 92 %

Accuracy of the pickup network on the 58 test images: 95 %

Accuracy of the sedan network on the 865 test images: 99 %

Accuracy of the van network on the 46 test images: 85 %





תוצאות דוגמאות



general_class: small,
sub_class: hatchback,
color: other,
open_cargo_area: 0,
wrecked: 0 , sunroof: 0,
luggage_carrier: 0,
enclosed_cab: 0,
spare_wheel: 0



general_class: small,
sub_class: jeep,
color: blue,
open_cargo_area: 0,
wrecked: 0 , sunroof: 1,
luggage_carrier: 0,
enclosed_cab: 0,
spare_wheel: 0



general_class: large,
sub_class: crane truck,
color: white,
open_cargo_area: 0,
wrecked: 0 , flatbed: 0,
enclosed_box: 0,
soft_shell_box: 0,
ladder: 0



סיכום

בפרויקט זה התמודדנו עם בעיית סיווג מורכבת, תוך התמודדות עם מדגם לא מאוזן.

הצגנו את הארכיטקטורה ההיררכית שבה השתמשנו, ודרכי ההתמודדות עם חוסר האיזון (משקול פונקצית מחיר, אוגמנטציה סלקטיבית).
הגענו לתוצאות טובות מאד, גם עבור המחלקות הדלות במידע וללא שימוש ב Boosting בזבזני.



מסקנות

- ניתוח התפלגות המידע ביחס למחלקות הסיווג הוא קריטי עבור בעיות סיווג.
 - במקרה של מידע לא מאוזן, אין משמעות לאחוז דיוק עבור מדגם מייצג. צריך לייצר מדגם מאוזן ולבדוק עבורו.
 - שימוש בסיווג היררכי תלוי עבור הבעיה המורכבת שקיבלנו, הוביל לתוצאות טובות מאד. **המסקנה העיקרית מפרויקט זה היא שכדאי לחקור את ההשפעה של סיווג היררכי תלוי של תמונות, גם אם מורכבות הבעיה לא נובעת מעודף מאפיינים לסיווג**
- למשל, אם צריך לסווג תמונות של רכבים לסוגים הבאים: פרטי, ג'יפ, משאית ואוטובוס, עם מידע לא מאוזן, נציע לסווג ל- גדול \ קטן ואז לסווג לפי תוצאת הסיווג הראשון.



References

- [1] Krizhevsky Alex, Ilya Sutskever and Geoffrey E. Hinton, "ImageNet classification with deep convolutional neural networks", Advances in neural information processing systems, 2012.
- [2] Kaiming He, Xiangyu Zhang, Shaoqing Ren and Jian sun, "Deep Residual Learning for Image Recognition", 2015.
- [3] Vicente Garcia, Ana I. Marques and J. Salvador Sanchez "Improving Risk Predictions by Preprocessing Imbalanced Credit Data", 2012.
- [4] Kamran Kowsari , Donald E. Brown, Mojtaba Heidarysafa, Kiana Jafari Meimandi , Matthew S. Gerber and Laura E. Barnes, "HDLTex: Hierarchical Deep Learning for Text Classification", 2017.